Detección de fauna con YOLOv8 en CCT-20: generalización entre cámaras, robustez visual y monitoreo ecológico reproducible

Christian André Urviola García **Alex Reynaldo Pomazón Solórzano**
Alexander André Chávez Cabana **Andhersson Manuel Salazar Fernández**

Universidad Nacional de Ingeniería (UNI), FIIS
Redes Neuronales y Aprendizaje Profundo, Grupo 2, 2026-II
Informe de investigación – Pregunta 3 del examen parcial

Abstract

Las cámaras trampa permiten vigilar fauna de forma no invasiva, pero sus imágenes presentan desbalance extremo, fondos recurrentes y cambios de dominio entre ubicaciones. Evaluamos dos detectores ajustados, YOLOv8n y YOLOv8s, sobre 48 095 fotografías elegibles del subconjunto CCT-20, con particiones que distinguen cámaras conocidas (CIS) y no vistas (TRANS). En una reproducción independiente mediante pesos publicados, YOLOv8s obtuvo mAP@0.5 de 72.41 % en CIS TEST y 43.96 % en TRANS TEST; la brecha macro entre las 13 especies compartidas fue de $-29{,}95$ puntos porcentuales. Sobre TEST completo, los animales pequeños redujeron su recall de 66.41 % a 49.01 %, y la tasa de falsas alarmas en fotografías negativas subió de 13.64 % a 21.93 %. Dos auditorías independientes de oclusión (94 y 218 casos evaluables), junto con una perturbación del fondo, identifican restricciones adicionales. Un módulo ecológico procesó 48 imágenes de 19 secuencias reales de una cámara TRANS y generó reportes por especie y fecha. El pipeline descarga datos y checkpoints públicos y reproduce evaluaciones; no se considera verificado el reentrenamiento integral desde cero. Los resultados respaldan un sistema de apoyo a especialistas, sujeto a validación geográfica y supervisión humana.

1. Introducción

Las cámaras trampa documentan presencia y actividad de fauna de manera no invasiva, pero generan volúmenes de imágenes cuya inspección manual es costosa. Los avances en aprendizaje profundo han permitido automatizar parcialmente su clasificación y análisis [Norouzzadeh et al., 2018, Tabak et al., 2019]; sin embargo, la automatización puede ocultar fallos de detección que sesgan decisiones ecológicas. Un desafío central es que cada cámara permanece fija: vegetación, rocas y patrón de luz son altamente recurrentes. Un detector podría aprovechar esas correlaciones en lugar de reconocer exclusivamente la apariencia del animal [Beery et al., 2018, Geirhos et al., 2020].

Investigamos la pregunta: *¿cuánto se deteriora el rendimiento de YOLOv8 al pasar de ubicaciones de cámara observadas durante el entrenamiento a ubicaciones nuevas, y qué limitaciones aparecen por tamaño, oclusión y fondo?* Además del análisis de detección, implementamos reportes de monitoreo por cámara y secuencia. Nuestras contribuciones son: (i) un protocolo reproducible sobre particiones CIS/TRANS de CCT-20; (ii) una comparación controlada de dos capacidades de YOLOv8; (iii) un análisis de robustez con auditoría manual explícita; y (iv) un módulo funcional de agregación temporal. El objetivo es priorizar *validez fuera de distribución* y trazabilidad por encima de una única cifra de exactitud.

Preprint.

Tabla 1: Trazabilidad desde el subconjunto ECCV de CCT-20 hasta el material elegible. La evaluación representa el subconjunto filtrado, no las 243 100 imágenes de la colección general.

Partición	Originales	Utilizadas	Excluidas
TRAIN	13 553	12 099	1 454
CIS VAL	3 484	2 619	865
TRANS VAL	1 725	1 594	131
CIS TEST	15 827	13 085	2 742
TRANS TEST	23 275	18 698	4 577
Total	**57 864**	**48 095**	**9 769**

2. Trabajos relacionados

Beery et al. [2018] introdujeron la evaluación de reconocimiento entre ubicaciones mediante imágenes de cámaras trampa, mostrando que un buen desempeño en escenas familiares no garantiza transferencia. Norouzzadeh et al. [2018] utilizaron redes profundas para identificar y describir animales en grandes colecciones fotográficas. Tabak et al. [2019] estudiaron clasificación automática en ecología y evaluación fuera de muestra; posteriormente, Tabak et al. [2020] enfatizaron la accesibilidad y transferibilidad de herramientas ecológicas. Estos enfoques sustentan el paso de clasificación aislada a sistemas aplicables a nuevas localizaciones.

En términos conceptuales, Geirhos et al. [2020] describen el aprendizaje de atajos visuales, pertinente para fondos estáticos de cámaras. Selvaraju et al. [2017] presentan Grad-CAM como una vía para interpretar regiones influyentes; aquí no atribuimos interpretabilidad de gradientes al modelo, sino que empleamos una intervención de contexto como indicio complementario, con limitaciones causales explícitas. Para detección adoptamos la implementación abierta de YOLOv8 [Ultralytics, 2026], evaluada con convenciones de mAP e IoU relacionadas con el marco COCO [Lin et al., 2014].

3. Datos y preparación

3.1. Origen, clases y particiones

CCT-20 es una referencia reducida de *Caltech Camera Traps*, accesible desde LILA BC, cuyo conjunto general contiene 243 100 fotos de 140 ubicaciones y aproximadamente 66 000 anotaciones de cajas [LILA BC, 2026, Beery et al., 2018]. Utilizamos las imágenes reducidas y los JSON originales con particiones `train`, `cis_val`, `trans_val`, `cis_test` y `trans_test`. Se conservaron 14 clases de fauna con cajas utilizables: `badger`, `bird`, `bobcat`, `cat`, `coyote`, `deer`, `dog`, `fox`, `opossum`, `rabbit`, `raccoon`, `rodent`, `skunk` y `squirrel`. No se afirma cobertura de todas las 21 categorías originales.

3.2. Conversión y tratamiento de fondos

Las cajas de formato COCO (x, y, w, h) se recortaron a los límites de la fotografía y se normalizaron para YOLO como $(x_c/W, y_c/H, w/W, h/H)$. Se descartaron cajas de área nula y fotografías con fauna anotada pero sin cajas suficientes para supervisión de localización. **Una imagen con animal sin caja no se convirtió en fondo negativo.** El entrenamiento retuvo 11 431 fotografías de fauna con cajas y 668 imágenes `car`-only, etiquetadas con archivo YOLO vacío para aprender ausencia de las 14 especies objetivo. No se encontraron imágenes explícitamente `empty` en este subconjunto `train`; por tanto, los negativos de entrenamiento *no reproducen la prevalencia de vacíos del conjunto completo*. Esto limita la calibración de ausencia de fauna. El soporte de cajas de TRAIN es muy desigual: `fox` (5), `badger` (9), `deer` (44), `rodent` (264), `rabbit` (2 278) y `opossum` (2 514); la relación entre extremos alcanza 503:1. No tratamos `car` como una especie animal.

Las particiones siguieron la separación oficial de las 20 ubicaciones del benchmark: diez ubicaciones CIS y diez TRANS, sin intersección entre ambos conjuntos. No se comparten fotografías entre TRAIN y TEST, ni secuencias entre TRAIN y CIS TEST; sin embargo, una auditoría de metadatos identificó 70 secuencias compartidas entre TRAIN y CIS VAL, una precaución importante al interpretar la

Tabla 2: Reproducción independiente de métricas TEST a partir de los checkpoints finales (%). Precisión y recall son los promedios internos reportados por Ultralytics.

Modelo	TEST	Prec.	Recall	mAP50	mAP50:95
YOLOv8n	CIS	82.23	64.01	71.13	46.02
YOLOv8s	CIS	80.19	70.22	**72.41**	**47.08**
YOLOv8n	TRANS	45.49	42.68	37.57	23.06
YOLOv8s	TRANS	**64.10**	**43.80**	**43.96**	**27.42**

selección de pesos. La validación para seleccionar el mejor `best.pt` se realizó en `cis_val`; el resultado TRANS sirve para estudiar transferencia, no para ajustar el entrenamiento.

4. Arquitectura y diseño experimental

4.1. Fine-tuning y configuración

Comparamos **YOLOv8n** (nano) y **YOLOv8s** (small), inicializados desde checkpoints preentrenados y adaptados a 14 clases. Los dos usaron 20 èpocas máximas, tamaño de entrada 640×640, `batch=16`, optimizador AdamW, $lr_0 = 0{,}0006$, $lrf = 0{,}10$, programación coseno, `patience=6`, semilla 0 y entrenamiento de precisión mixta. Los aumentos incluyeron perturbación HSV $(0{,}015, 0{,}50, 0{,}30)$, volteo horizontal con probabilidad 0.50, mosaico 0.50 y desactivación del mosaico en las ùltimas cinco èpocas; `mixup=0`. Se mantuvieron estas decisiones entre arquitecturas, cambiando únicamente el punto de partida `yolov8n.pt` frente a `yolov8s.pt` [Ultralytics, 2026].

El entrenamiento original se realizó en Colab con NVIDIA L4. La reproducción independiente de evaluación se ejecutó en Windows sobre CPU (Ultralytics 8.4.184, Python 3.13.9), a partir de archivos y pesos descargados públicamente; se verificó de forma separada compatibilidad CUDA de una RTX 5050 Laptop GPU, sin atribuirle las métricas calculadas en CPU. Los modelos y la evaluación no son entrenados con las fotografías TEST. La selección posterior de YOLOv8s como detector final utiliza el rendimiento exploratorio ya inspeccionado en TEST; esta decisión debe interpretarse como **comparación de investigación, no como prueba ciega de selección de arquitectura**.

4.2. Métricas y protocolo

Medimos precisión, recuperación (*recall*), mAP_{50} y $\mathrm{mAP}_{50:95}$ sobre cada partición TEST. Para $\mathrm{mAP}_{50:95}$ se promedian umbrales de IoU de 0.50 a 0.95 en pasos de 0.05, siguiendo el esquema de detección de objetos. El mAP se agrega entre clases evaluables; como `deer` no se evalúa en TRANS TEST, calculamos además una brecha estrictamente comparable promediando solo las **13 especies presentes en ambas particiones**:

$$\Delta_{\mathrm{geo}} = 100 \left[\frac{1}{|\mathcal{C}|} \sum_{c \in \mathcal{C}} AP_{50,c}^{\mathrm{TRANS}} - \frac{1}{|\mathcal{C}|} \sum_{c \in \mathcal{C}} AP_{50,c}^{\mathrm{CIS}} \right], \quad |\mathcal{C}| = 13. \tag{1}$$

Esta medida no debe confundirse con la simple resta entre los mAP globales cuando cambia el conjunto de clases evaluadas.

5. Resultados cuantitativos

5.1. Comparación de arquitecturas

YOLOv8s mejora el mAP@0.5 sobre YOLOv8n en 1.28 puntos CIS y 6.39 puntos TRANS. Ambos modelos se deterioran fuera de ubicaciones conocidas, especialmente al medir detecciones estrictas con IoU 0.50:0.95. Las pequeñas diferencias respecto a la primera ejecución en L4 (p. ej., CIS YOLOv8s: 72.47 % original frente a 72.41 % reproducido) son consistentes con variaciones del entorno de inferencia, sin constituir una estimación de incertidumbre experimental.

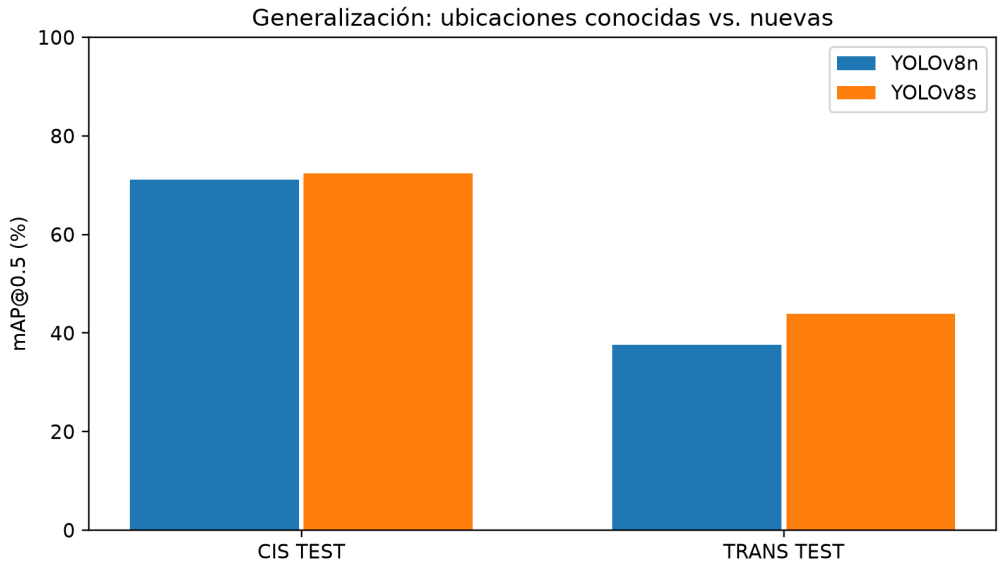


Figura 1: mAP@0.5 global de ambas arquitecturas en ubicaciones conocidas (CIS) y no vistas (TRANS). Las barras se derivan de los CSV de la reproducción externa sobre TEST completo.

Tabla 3: Desglose por especie de YOLOv8s en la reproducción externa. n: cajas de referencia en TEST; AP en porcentajes. `deer` no tiene objetos TRANS.

	CIS TEST			TRANS TEST		
Especie	n	AP50	AP50:95	n	AP50	AP50:95
badger	4	0.22	0.15	15	4.12	2.48
bird	752	60.45	32.00	180	5.35	2.98
bobcat	772	82.12	58.76	1 979	64.18	43.13
cat	1 528	92.95	63.13	1 366	30.86	20.03
coyote	1 182	94.20	71.53	1 902	61.50	43.53
deer	140	52.96	37.07	0	–	–
dog	725	75.21	52.97	961	67.18	45.70
fox	2	25.60	25.35	1	0.06	0.06
opossum	4 010	95.69	53.18	4 663	89.86	47.29
rabbit	1 559	90.14	56.33	722	69.79	37.49
raccoon	981	94.08	62.34	4 803	79.74	52.23
rodent	146	82.48	44.00	26	1.87	0.62
skunk	162	94.01	62.60	273	64.50	42.33
squirrel	510	73.61	39.73	782	32.49	18.58
Macro (13)	–	**73.91**	–	–	**43.96**	–

5.2. Generalización por especie y desbalance

Para las 13 especies presentes en ambos grupos de cámaras, la brecha comparable fue de $-35{,}10$ **puntos** para YOLOv8n (72.67 % CIS frente a 37.57 % TRANS) y de $-29{,}95$ **puntos** para YOLOv8s (73.91 % CIS frente a 43.96 % TRANS). El conjunto TRANS no incluye objetos `deer`, por lo que comparar sin este ajuste los mAP generales introduce una diferencia en el conjunto de especies.

`opossum` conserva AP50 alto en ambas geografías, pero `rodent`, `bird` y `cat` caen fuertemente. El soporte de TRAIN también está desbalanceado: `fox` tiene 5 cajas y `badger` 9, frente a 2 514 de `opossum`. En TRANS TEST, `fox` aporta solo una caja y `badger` 15; sus AP son estadísticamente inestables. No atribuimos los errores exclusivamente a rareza, porque también intervienen cambios de cámara, tamaño y calidad de anotación.

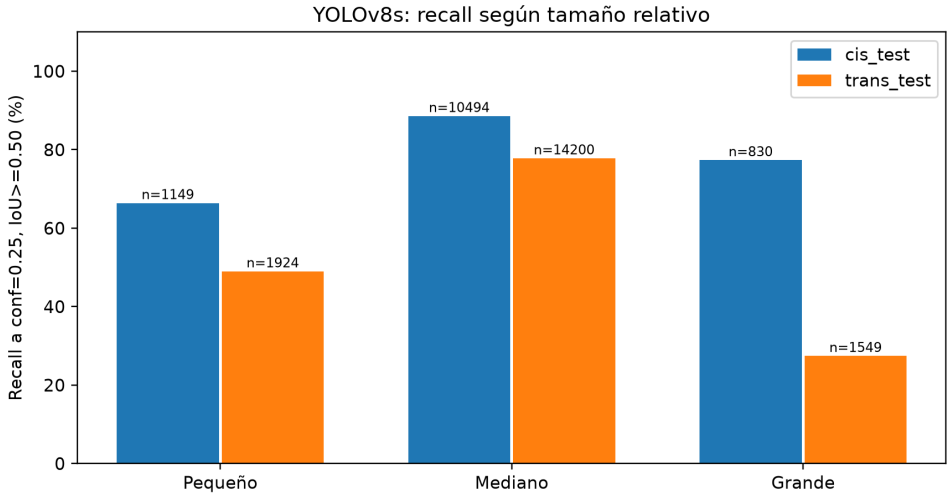


Figura 2: YOLOv8s: recall por tamaño de caja en ambas regiones de evaluación, con cantidad de objetos por grupo.

6. Robustez visual y dependencia del contexto

6.1. Tamaño relativo y falsas alarmas

Se completó el análisis de robustez sobre el detector seleccionado, **YOLOv8s**, con las 31 783 fotografías de TEST. Las cajas se agruparon por proporción de área del fotograma: pequeñas ($< 1\,\%$), medianas ($1\,\%$ a $< 10\,\%$) y grandes ($\geq 10\,\%$). Las predicciones se emparejaron uno a uno por especie, confianza $\geq 0{,}25$ e IoU $\geq 0{,}50$. Estas tasas son *recall por objeto*, no mAP calculado dentro del estrato. En CIS, el recall de objetos pequeños, medianos y grandes fue 66.41 %, 88.60 % y 77.35 % ($n = 1\,149$, 10 494 y 830); en TRANS cayó a 49.01 %, 77.82 % y 27.44 % ($n = 1\,924$, 14 200 y 1 549). El descenso en objetos grandes puede estar influido por cajas extremas o diferencias de anotación, no solo por transferencias geográficas. En fotografías sin cajas de fauna objetivo hubo 161/1 180 falsas alarmas por imagen en CIS (13.64 %) y 390/1 778 en TRANS (21.93 %). Esto corresponde a 242 y 464 cajas falsas, respectivamente, o a 20.51 y 26.10 cajas por cada 100 fotos negativas. La probabilidad de falsa alarma aumentó 8.29 puntos porcentuales en ubicaciones nuevas, reforzando la importancia de vigilar tanto omisiones como activaciones incorrectas.

6.2. Auditorías manuales de oclusión

La primera auditoría visual de 120 anotaciones TEST confirmó 94 objetos evaluables: 84 de oclusión baja, diez media y **ninguno de oclusión alta**. Los 26 restantes se excluyeron por problemas de evaluabilidad. En baja, YOLOv8n detectó 65/84 (77.38 %) y YOLOv8s 70/84 (83.33 %); en media, ambos detectaron 6/10 (60.00 %). Esta primera muestra se conserva como resultado independiente.

Se completó una **segunda auditoría humana**, con 240 objetos muestreados aleatoriamente (120 CIS TEST y 120 TRANS TEST; semilla 2026). De ellos, 218 resultaron evaluables, incluidos 13 con oclusión alta. La recuperación de YOLOv8s se determinó reutilizando el matching por especie 1:1 de TEST completo (confianza $\geq 0{,}25$, IoU $\geq 0{,}50$). La Tabla 4 documenta numeradores y denominadores. **No se mezclaron las dos muestras** ni se ajustaron sus etiquetas a las predicciones del modelo. Aunque la tasa observada en alta fue elevada, el soporte de ese estrato es **insuficiente para establecer una ventaja frente a oclusiones severas**; además, la muestra está estratificada por partición, no por especie. La figura resume los tres estratos del segundo muestreo. Los registros auditados están disponibles en el repositorio, en `auditorias/oclusion_adicional/`.

6.3. Intervención del fondo

Para indagar posible dependencia del contexto, comparamos la detección de YOLOv8s en los mismos 94 casos antes y después de desenfocar el entorno exterior a la caja real del animal, preservando

Tabla 4: Auditoría independiente de 240 casos; 218 evaluables. Recall por objeto de YOLOv8s, no mAP. La oclusión alta en TRANS tiene solo dos casos.

Partición	Baja	Media	Alta
CIS TEST	78/86 (90.70 %)	13/15 (86.67 %)	10/11 (90.91 %)
TRANS TEST	67/85 (78.82 %)	12/19 (63.16 %)	2/2 (100.00 %)
Total	**145/171 (84.80 %)**	**25/34 (73.53 %)**	**12/13 (92.31 %)**

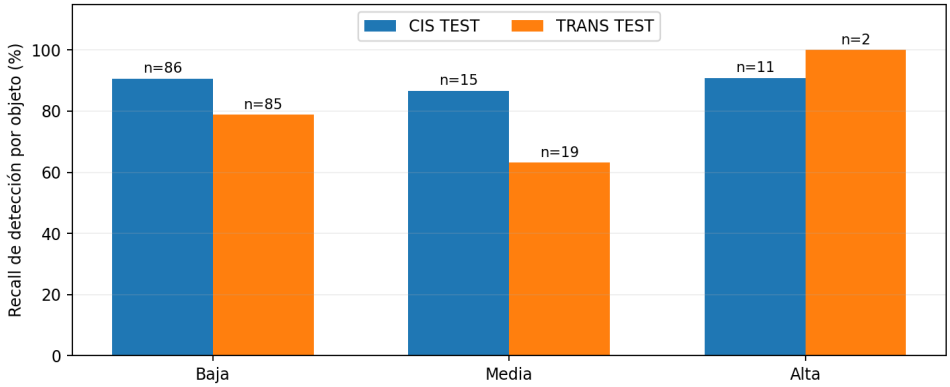


Figura 3: Recall de YOLOv8s por nivel manual de oclusión en la segunda auditoría (218 objetos evaluables). Los denominadores se muestran sobre las barras; no representa mAP ni confianza estadística.

aproximadamente su interior y aplicando una transición suavizada. Se utilizó confianza $\geq 0{,}25$, coincidencia de especie e IoU$\geq 0{,}50$. El recall en CIS descendió de 48/51 (94.12 %) a 43/51 (84.31 %), una variación de $-9{,}81$ puntos; en TRANS se mantuvo 28/43 (65.12 %) antes y después. Hubo seis detecciones que desaparecieron y una que apareció al alterar el contexto, a través del total de la muestra.

El descenso en CIS constituye evidencia de sensibilidad al contexto para algunos ejemplos, *no* una demostración causal de que el modelo memorice una roca o vegetación. La operación utiliza cajas reales, no disponibles en despliegue, y el desenfoque puede cambiar contornos u otras pistas indirectas. Un estudio de activaciones del backbone, con enmascaramientos controlados y más cámaras, permitiría contrastar con mayor fuerza la hipótesis de atajos visuales [Geirhos et al., 2020, Selvaraju et al., 2017].

7. Módulo de monitoreo ecológico

Se implementó un posprocesamiento por reglas que recibe fotografías, detecciones YOLOv8s y metadatos oficiales de cámara, secuencia y fecha. Los reportes distinguen *fotografías con especie*, *cajas detectadas*, *secuencias con predicción* y actividad diaria u horaria. Una secuencia con detecciones repetidas no representa varios individuos; los conteos obtenidos miden **actividad predicha**, no abundancia biológica verificada.

La demostración reproducida seleccionó **48 fotografías reales de la cámara TRANS 46**, pertenecientes a **19 secuencias**, de las cuales 16 contienen varios fotogramas. Se observaron 38 fotos con alguna detección (79.17 %), diez sin detección (20.83 %) y 40 cajas correspondientes a cinco especies predichas. Las secuencias contienen capturas de **2011 y 2012**: son eventos de dos periodos históricos, no un muestreo temporal continuo. El detalle se muestra en la Tabla 5; las 40 cajas corresponden a 18 pares *(secuencia, especie)*.

8. Discusión crítica y limitaciones

Generalización y sesgo de muestreo. El modelo más grande mejora el mAP en cámaras nuevas, pero la brecha macro de 29.95 puntos persiste y las especies no cambian uniformemente. Las cifras

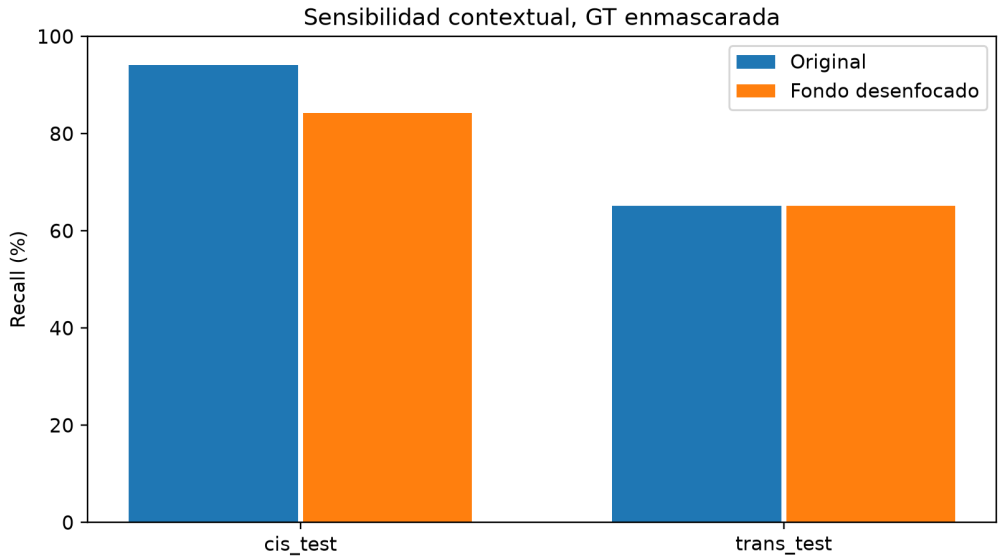


Figura 4: Prueba de sensibilidad al contexto visual en YOLOv8s, con 51 casos CIS y 43 TRANS. Una diferencia de recall por desenfoque no equivale a una prueba de memorización: la intervención también crea un cambio de dominio artificial.

Tabla 5: Demostración ecológica: cámara TRANS 46, YOLOv8s final. Los eventos son secuencias con detección de la especie, no individuos distintos.

Especie predicha	Fotos	Cajas	Secuencias
`opossum`	23	24	10
`bobcat`	9	9	4
`rabbit`	4	4	2
`squirrel`	2	2	1
`raccoon`	1	1	1
Total	–	**40**	**18***

*Suma de pares secuencia–especie, no 18 secuencias necesariamente distintas.

solo representan 48 095 imágenes elegibles del subconjunto CCT-20; descartar 9 769 fotografías y entrenar con negativos `car`-only, en lugar de un muestreo ecológico amplio de vacíos, limita la representatividad. Las secuencias compartidas entre TRAIN y CIS VAL y la exploración de una segunda arquitectura sobre TEST hacen que la selección de modelos no sea ciega.

Interpretación de robustez. Los umbrales de confianza 0.25 e IoU 0.50 son fijos; el recall por tamaño/oclusión no debe confundirse con mAP. La segunda auditoría incluye 13 objetos de alta oclusión, pero su escaso soporte impide inferencias robustas en ese estrato. El desenfoque del fondo, aunque reduce en 9.81 puntos el recall de una muestra CIS, crea una alteración visual artificial y no identifica por sí mismo aprendizaje espurio causal. El valor anómalo de grandes cajas TRANS merece una auditoría de calidad y un análisis de sensibilidad excluyendo cajas casi del tamaño total de la imagen.

Reproducibilidad. Se comprobaron doce pruebas automatizadas y, en un entorno Windows independiente, descarga de TAR y pesos públicos, preparación de los cinco subconjuntos y reevaluación completa de ambos detectores sobre 31 783 imágenes TEST por modelo. Se reprodujeron además diagnósticos de YOLOv8s, la primera auditoría manual publicada (120 registros) y el análisis adicional de 240 objetos auditados, la intervención de fondo y el reporte ecológico multiframe. El comando principal `python reproducir.py -base ./trabajo -gpu` automatiza el flujo con entrenamiento, condicionado a disponer de GPU y recursos suficientes; el modo `-pesos-publicos` reutiliza checkpoints. **No afirmamos haber completado una prueba independiente de reentrenamiento integral desde cero mediante un solo comando.** La implementación del detector se basa en Ul-

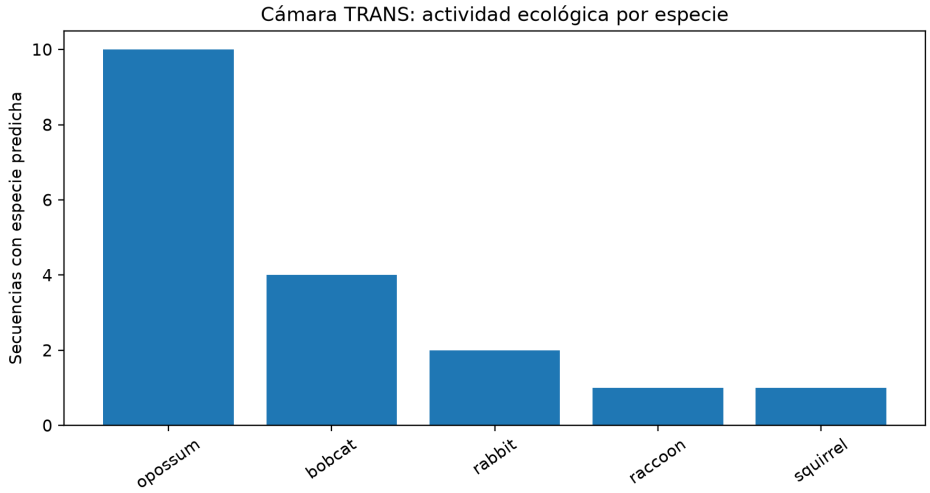


Figura 5: Reportes agregados por especie en una cámara no vista. Se grafican eventos por secuencia, sin inferir individuos ùnicos.



Figura 6: Ejemplo de tres fotogramas consecutivos de una misma secuencia real en cámara 46 (04/05/2011, 05:49:48–50). El animal se desplaza entre capturas; una secuencia no equivale a tres individuos.

tralytics; la contribución propia reside en el filtrado, protocolo de evaluación, diagnósticos y módulo ecológico.

9. IA responsable para conservación

La gestión responsable de detección automática en áreas naturales debe partir de una asimetría entre errores. Un **falso negativo** puede ocultar la presencia de una especie amenazada, subestimar su distribución o hacer que un equipo descarte injustificadamente una ubicación como de baja prioridad. Para poblaciones raras, una tasa de omisión aparentemente moderada puede traducirse en una pérdida sustantiva de evidencia biológica. No debería usarse una ausencia de detección automática como prueba definitiva de ausencia del taxón. Recomendamos umbrales calibrados por especie, muestreo humano periódico de imágenes sin detección y revisión reforzada para especies de especial interés.

Un **falso positivo** también tiene costos: ocasiona inspecciones innecesarias, contamina series temporales y puede generar falsas alertas. Por ello, la automatización debe facilitar una cola de revisión priorizada que muestre fotografías, clase, confianza, fecha y ubicación de cada predicción, sin ocultar la incertidumbre. Los porcentajes de fotografías con o sin detección no deben traducirse automáticamente en número de individuos, riqueza real ni tendencia poblacional. Los conteos por secuencia requieren reglas ecológicas explícitas sobre recapturas y dependencia temporal.

Finalmente, la brecha de $-29{,}95$ puntos en mAP50 para especies comparables evidencia un **riesgo geográfico relevante**. Antes de desplegar el modelo en una región diferente —en especial si se pretende usarlo en ecosistemas amazónicos o andinos— deben reunirse datos de referencia locales, cuantificar sensibilidad por especie y revalidar el detector en cámaras independientes. Es necesario mantener supervisión de especialistas, registro de fallos y monitoreo de cambios de dominio, y respetar restricciones de acceso a coordenadas de especies vulnerables para evitar divulgación de

ubicaciones sensibles. El sistema propuesto es un apoyo a la decisión, no un sustituto de expertos en conservación.

10. Conclusiones

En el benchmark elegible de CCT-20, YOLOv8s obtuvo un mAP@0.5 de 72.41 % en CIS TEST y 43.96 % en TRANS TEST, con brecha comparable de 29.95 puntos. La mejora sobre YOLOv8n no resuelve la transferencia geográfica. El nuevo diagnóstico del modelo final cuantifica caídas por escala, incremento de falsas alarmas en fotografías negativas y sensibilidad contextual en una muestra controlada. El módulo funcional genera actividad por cámara, especie y fecha en secuencias reales, pero no estima abundancia ni verifica presencia ecológica. El trabajo aporta un pipeline reproducible de evaluación y reportes, acompañado de limitaciones explícitas sobre datos, escasa muestra de oclusión severa y selección experimental.

Disponibilidad de código y datos

Código: `https://github.com/andreurviolaa-jpg/Pregunta-3-YOLO`. Datos fuente: CCT-20 de LILA BC [LILA BC, 2026]; por tamaño y condiciones de distribución, las fotografías originales no se duplican en GitHub. Reproducción de evaluación en Windows y código disponible para ejecución independiente; octubre de 2026.

Referencias

Sara Beery, Grant Van Horn, and Pietro Perona. Recognition in terra incognita. In *Proceedings of the European Conference on Computer Vision (ECCV)*, pages 456–473, 2018. doi: 10.1007/978-3-030-01270-0_28.

Robert Geirhos, Jørn-Henrik Jacobsen, Claudio Michaelis, Richard Zemel, Wieland Brendel, Matthias Bethge, and Felix A. Wichmann. Shortcut learning in deep neural networks. *Nature Machine Intelligence*, 2:665–673, 2020. doi: 10.1038/s42256-020-00257-z.

LILA BC. Caltech camera traps: Dataset and cct20 benchmark. `https://lila.science/datasets/caltech-camera-traps`, 2026. Catálogo oficial de datos, accesado en octubre de 2026.

Tsung-Yi Lin, Michael Maire, Serge Belongie, James Hays, Pietro Perona, Deva Ramanan, Piotr Dollár, and C. Lawrence Zitnick. Microsoft COCO: Common objects in context. In *European Conference on Computer Vision*, pages 740–755, 2014. doi: 10.1007/978-3-319-10602-1_48.

Mohammad Sadegh Norouzzadeh, Anh Nguyen, Margaret Kosmala, Alexandra Swanson, Meredith S. Palmer, Craig Packer, and Jeff Clune. Automatically identifying, counting, and describing wild animals in camera-trap images with deep learning. *Proceedings of the National Academy of Sciences*, 115(25):E5716–E5725, 2018. doi: 10.1073/pnas.1719367115.

Ramprasaath R. Selvaraju, Michael Cogswell, Abhishek Das, Ramakrishna Vedantam, Devi Parikh, and Dhruv Batra. Grad-CAM: Visual explanations from deep networks via gradient-based localization. In *Proceedings of the IEEE International Conference on Computer Vision*, pages 618–626, 2017. doi: 10.1109/ICCV.2017.74.

Michael A. Tabak, Mohammad S. Norouzzadeh, David W. Wolfson, et al. Machine learning to classify animal species in camera trap images: Applications in ecology. *Methods in Ecology and Evolution*, 10(4):585–590, 2019. doi: 10.1111/2041-210X.13120.

Michael A. Tabak, Mohammad S. Norouzzadeh, David W. Wolfson, et al. Improving the accessibility and transferability of machine learning algorithms for identification of animals in camera trap images: Mlwic2. *Ecology and Evolution*, 10(19):10374–10383, 2020. doi: 10.1002/ece3.6692.

Ultralytics. Ultralytics YOLO: Documentation and open-source implementation. `https://docs.ultralytics.com/`, 2026. Consultado en octubre de 2026.